

# Algoritmo Genético Aplicado ao Controle de Tensão em Sistemas Elétricos de Potência

Frederico Antônio Pinheiro  
Alan Neiba Moreira  
Eduardo Nohme Cardoso  
João Antônio de Vasconcelos

Centro de Pesquisa e Desenvolvimento em Engenharia Elétrica - CPDEE  
Universidade Federal de Minas Gerais - UFMG  
Av. Antônio Carlos, 6627 - 31270-901 Belo Horizonte MG - Brasil  
joao@cpdee.ufmg.br & antonio@cpdee.ufmg.br

**Abstract:** In this paper, the Genetic Algorithm (GA) is coupled to a Load Flow Program, for voltage control in Electrical Power Systems. The GA is based on the analogy between optimization and natural evolution of the species, combining the concepts of selective adaptation and survival of the fittest. The proposed method was applied to the 14 and 30 IEEE bus test systems. The numerical results show that the GA's are powerful techniques to solve this type of problems.

**Key words:** Genetic Algorithm, Load Flow Program, Electrical Power System, Optimal Power Flow.

**Resumo:** Neste artigo, o Algoritmo Genético (GA) é acoplado a um Programa de Fluxo de Carga (PFC), para controle de tensão em Sistemas Elétricos de Potência (SEP). O GA se baseia na analogia entre otimização e evolução natural das espécies, combinando os conceitos de adaptação seletiva e sobrevivência dos indivíduos mais capazes. O método proposto foi aplicado aos sistemas testes de 14 e 30 barras do IEEE. Os resultados numéricos mostram que os GA's são técnicas poderosas para solucionar estes tipos de problemas.

## 1. INTRODUÇÃO

Dentre os métodos de otimização utilizados para controle de tensão de sistemas elétricos, duas grandes famílias se destacam: determinísticos e estocásticos [10].

Os métodos determinísticos mais eficientes necessitam, na grande maioria, de cálculo de derivadas da função objetivo para a determinação da direção de busca para a pesquisa do ponto de mínimo. O ponto solução obtido é geralmente um ponto de mínimo local, próximo do ponto inicial. As suas grandes desvantagens são a necessidade de cálculo de derivadas e a não garantia do mínimo global.

Já os métodos estocásticos, não necessitam de cálculos de derivadas e são capazes de encontrar a solução global. Porém, o número de avaliações da função objetivo, necessárias para se chegar à solução, é normalmente superior ao número requerido pelos métodos determinísticos.

Dentre os métodos de otimização estocásticos, encontramos o Algoritmo Genético (GA). O GA, consiste na analogia entre otimização e a evolução natural das espécies, combinando os conceitos de adaptação seletiva e sobrevivência dos indivíduos mais capazes. A utilização do GA para solucionar problemas, como controle de tensão em sistemas elétricos de potência, tem como grande vantagem a robustez do método em relação aos métodos determinísticos [7-10].

Este trabalho descreve um método de otimização baseado em Algoritmo Genético (GA), acoplado a um programa de fluxo de carga, na intenção de se conseguir um controle de tensão em sistemas elétricos de potência. O método proposto foi aplicado aos sistemas testes de 14 e 30 barras do IEEE. Os resultados numéricos são apresentados e discutidos.

## 2. CONTROLE DE TENSÃO EM SISTEMAS ELÉTRICOS DE POTÊNCIA

O problema de controle de tensão em sistemas elétricos de potência é formulado como um caso particular do problema de fluxo de potência ótimo, em que somente o controle de tensão é considerado. O

cálculo de fluxo de potência em uma rede de energia elétrica consiste essencialmente na determinação do estado da rede, da distribuição dos fluxos e de algumas outras grandezas de interesse, como por exemplo, as tensões nas barras da rede[1-6].

O principal objetivo na otimização de sistemas elétricos, é operar o sistema de maneira ótima. Operação ótima significa, por exemplo, a operação com mínimas perdas e tensões nas barras dentro de limites rigorosamente fixados.

O Fluxo de Potência Ótimo (FPO) é um modelo de otimização não linear, não convexo, com potencial de aplicação no planejamento e na operação de Sistemas Elétricos de Potência (SEP). A operação de SEP requer o atendimento da carga, economia nos recursos disponíveis e observação dos limites operacionais dos equipamentos. O FPO procura estados de operação que cumpram estes três requisitos ao mesmo tempo, minimizando uma função objetivo sujeita a restrições funcionais não lineares [2].

Em todo sistema elétrico existe uma série de equipamentos que controlam determinadas variáveis, automaticamente ou não, e cujos efeitos não foram considerados no modelo apresentado. Entre esses, temos: controle de magnitude de tensão por ajuste de taps; controle de fluxo de potência ativa por transformador defasador; controle de fluxo de potência reativa por banco de capacitores / indutores e controle de intercâmbio em sistemas interligados.

Os limites de operação mais comuns e considerados no modelo são: limites de injeção de potência reativa em barras de tensão controlada e limites de tensão em barras de carga.

O PFC utilizado no acoplamento, foi desenvolvido no CPDEE e validado através dos sistemas testes de 6, 14, 30, 57 e 118 barras do IEEE.

### 3. ALGORITMO GENÉTICO (GA)

O GA proposto neste artigo, chamado de Algoritmo Genético Simples, consiste na analogia entre otimização e a evolução natural das espécies, combinando os conceitos de adaptação seletiva e sobrevivência dos indivíduos mais capazes. Ele baseia-se na representação cromossômica das variáveis de otimização, no processo de reprodução e nos operadores genéticos: cruzamento e mutação.

Em outras palavras, o GA compreende um conjunto de indivíduos (população) e um conjunto de operadores genéticos que atuam sobre a população. De acordo com a teoria da evolução, somente os indivíduos mais capazes de uma população sobrevivem, transmitindo desta forma o material genético destes indivíduos sobreviventes para os seus descendentes. Analogamente, o GA analisa um conjunto de soluções potenciais devidamente codificado (codificação binária, isto é, os indivíduos são strings de bits), que constitui a população. O GA então manipula os indivíduos mais aptos, utilizando-se dos operadores genéticos, para a obtenção de uma população otimizada [9].

O desempenho de um indivíduo é avaliado por uma função que será chamada função de adaptação. No Algoritmo Genético, o problema é naturalmente formulado em termos de maximização, diferentemente dos outros métodos onde o problema é formulado em termos de minimização.

#### 3.1. Estágios do Algoritmo Genético

Um ciclo do GA consiste dos seguintes estágios: (a) criação de uma população de soluções potenciais codificadas (indivíduos); (b) avaliação dos indivíduos; (c) seleção dos indivíduos mais capazes; (d) geração da nova população através de manipulações genéticas.

A princípio, o GA utiliza uma população de soluções potenciais criada por um gerador aleatório de valores lógicos verdadeiro ou falso (codificação binária). Nos estágios (b) e (c) é feita uma avaliação para a seleção dos mais capazes. A capacidade de cada indivíduo é determinada pelo valor da função de adaptação, relacionada com a função objetivo do problema. Esta seleção visa determinar os indivíduos genitores para serem utilizados no estágio (d). Dá-se o nome de reprodução à seleção dos indivíduos. Finalmente, no último estágio, pode-se realçar o papel dos operadores genéticos como fundamental para a obtenção da solução ótima.

#### 3.2. Esquemas de Seleção

Os esquemas de seleção fornecem um mecanismo para a escolha dos indivíduos mais capazes, que sobreviverão na nova geração. O GA utiliza o esquema de seleção proporcional, aqui implementado através do método da roleta.

No esquema de seleção proporcional, um indivíduo com valor de aptidão  $f_i$  gera  $f_i / f$  descendentes, onde  $f$  é a média dos valores da função de adaptação da população. Um indivíduo com valor da função de adaptação  $f_i$  maior que a média dos valores da função de adaptação da população, gera mais descendentes que no

caso oposto. Na implementação pelo método da roleta cada indivíduo corresponde a um setor circular de ângulo  $2\pi f_i / f$ . Um número gerado aleatoriamente entre 0 e  $2\pi$  determina qual o setor escolhido e o indivíduo correspondente.

### 3.3. Operadores Genéticos

Entre os indivíduos que foram selecionados no processo de reprodução, dois são escolhidos para se cruzarem. Desde que o cruzamento é realizado com uma probabilidade  $pc$ , a decisão para executá-la é tomada usando um gerador de números aleatórios para gerar um número entre 0 e 1. Se o número gerado é inferior a  $pc$ , o cruzamento é realizado. Um segundo número aleatório  $k$  ( $1 \leq k \leq l-1$ ) é necessário para determinar a posição de corte na cadeia de bits. Finalmente, o material genético do lado direito dessa posição de corte é permutada entre eles.

```

      →
A = 1 0 1 0 1 1 0 0 1 0
B = 1 1 1 1 1 1 1 1 0 0
      k=4
A' = 1 0 1 0 1 1 1 1 0 0
B' = 1 1 1 1 1 1 0 0 1 0

```

Esse processo é ilustrado acima para dois indivíduos  $A$  e  $B$  representados em código binário com comprimento  $l=10$  e posição de corte  $k=4$ . O resultado do processo são as duas cadeias de caracteres  $A'$  e  $B'$ , as quais têm características de  $A$  e  $B$ . Gera-se assim duas novas possíveis soluções. Este é o principal mecanismo na produção de novos pontos a serem testados.

De forma diferente, a mutação altera bits numa cadeia de caracteres com a probabilidade de mutação  $pm$ . Esta operação protege o processo de busca da solução contra perdas de valiosas características genéticas, durante as operações de reprodução e cruzamento, pela introdução de novas informações, permitindo novos pontos serem testados, aumentando, assim, a probabilidade de se encontrar o ótimo global.

Considere o indivíduo  $A$  do caso anterior. Este processo é realizado bit a bit. Supondo que o quinto bit ( $k=5$ ) esteja sob consideração, gera-se um número aleatório entre 0 e 1. Se esse número é inferior à probabilidade  $pm$ , a operação é executada e o valor do bit é modificado para se obter o novo indivíduo  $A'$ .

```

A = 1 0 1 0 1 1 0 0 1 0
A' = 1 0 1 0 0 1 0 0 1 0
      k=5

```

### 3.4. Parâmetros Genéticos

Parâmetros genéticos são entidades que determinam o desempenho do GA.

- **Tamanho da População** : O tamanho da população afeta a eficiência do algoritmo. Uma população pequena acarreta um fraco desempenho. Em contrapartida, uma população grande previne uma convergência prematura para soluções locais, além de aumentar o tempo de computação, tendo em vista que a mesma exige um maior número de avaliações da função objetivo. O GA usa tipicamente um tamanho de população entre 30 e 200.

- **Probabilidade de cruzamento ( $pc$ )**: a probabilidade de cruzamento é um valor percentual do número de indivíduos que experimentam cruzamento em relação ao número total de indivíduos de uma população. Uma alta probabilidade de cruzamento, em um GA sem elitismo, faz com que indivíduos, com alto desempenho, sejam eliminados antes mesmo que a seleção possa produzir aperfeiçoamentos. Por outro lado, uma baixa probabilidade de cruzamento pode convergir lentamente devido à baixa taxa de exploração das características genéticas. A probabilidade de cruzamento utilizada pelo GA varia entre 0,5 e 1,0.

- **Probabilidade de mutação ( $pm$ )**: a probabilidade de mutação é um valor percentual do número de bits escolhidos aleatoriamente para serem alterados em relação ao número total de bits da população. Uma baixa probabilidade de mutação não permite a restauração da diversidade da população, ao passo que uma alta probabilidade de mutação resulta em uma busca essencialmente aleatória. A taxa de mutação utilizada pelo GA varia entre 0,001 e 0,05.

## 4. ACOPLAMENTO ENTRE UM PROGRAMA DE FLUXO DE CARGA E UM GA

Qualquer problema de fluxo de carga pode ser acoplado a um Algoritmo Genético via uma função objetivo, conforme dito anteriormente. Em GA a função objetivo é formulada em termos de maximização, com uma função não negativa em todo o domínio de definição do problema [10].

O problema de otimização não linear de Controle de Tensão em Sistemas Elétricos de Potência pode ser formulado matematicamente como um problema do tipo:

$$\begin{aligned}
 &\text{minimize} && f(x) \\
 &\text{sujeito a} && g_i(x) \leq 0, \quad i = 1, 2, 3, \dots, m \\
 & && h_i(x) \leq 0, \quad i = 1, 2, 3, \dots, p \\
 & && x^{\min} \leq x \leq x^{\max}
 \end{aligned} \tag{1}$$

onde :

$x \in R^n \rightarrow$  vetor de variáveis de otimização;  
 $x^{min}, x^{max} \rightarrow$  limites de mínimo e máximo em  $x$ ;  
 $f(x) \rightarrow$  função objetivo;  
 $g_i(x), h_i(x) \rightarrow$  vetor de restrições de desigualdade.

Usando uma transformação como nos métodos de penalidade, o problema original (1), pode ser reescrito como um problema de minimização irrestrita. Neste caso, a função objetivo é uma combinação ponderada dos termos representando os valores programados para as tensões nas barras de carga e das penalidades relativas à violação das restrições operacionais (limites de tensão nas barras de carga e limites de reativos nas barras de tensão controlada). Assim, o problema original se transforma em:

$$\text{minimize } ff(x) = \sum_{i=1}^m (V_i - V_i^{esp})^2 + \alpha \sum_{i=1}^m (g_i(x))^2 + \lambda \sum_{i=1}^p (h_i(x))^2$$

onde:

$$g_i(x) \leq (V_i - V_{min})(V_i - V_{max})$$

$$h_i(x) \leq (Q_i - Q_i^{min})(Q_i - Q_i^{max}) \quad (2)$$

O ( )<sub>+</sub>, representado em (2), significa que somente restrições violadas são consideradas;  $V_i$ ,  $V_i^{esp}$ ,  $V_i^{min}$  e  $V_i^{max}$  são, respectivamente, as tensões calculada, especificada, e limites na  $i$ ésima barra de carga;  $Q_i$ ,  $Q_i^{min}$  e  $Q_i^{max}$  são os valores de reativos calculado e os respectivos limites na  $i$ ésima barra de tensão controlada;  $\alpha$  e  $\lambda$  são parâmetros de penalidade utilizados para enfatizar mais ou menos determinados termos do somatório.

O problema acima pode agora ser transformado em uma forma adequada ao Algoritmo Genético, isto é, em forma de maximização.

$$\text{maximize } f_T(x) = \frac{1}{[ff(x) + \varepsilon]} \quad (3)$$

onde  $\varepsilon$  é simplesmente uma constante que deve ser ligeiramente superior ao módulo do valor mínimo de  $ff(x)$  se  $ff(x)$  é inferior ou igual a zero e ligeiramente superior ao negativo do mínimo de  $ff(x)$  se  $ff(x)$  é maior que zero. A análise de alguns resultados com essa função aptidão tem mostrado que se acelera a convergência do algoritmo [10].

A metodologia é resumida como se segue:

- Forma-se aleatoriamente uma população de possíveis soluções (indivíduos), codificados como descrito anteriormente.

- No estágio de avaliação, a cada indivíduo corresponde um valor da função objetivo, avaliada com os resultados do programa de fluxo de carga (PFC).
- A seleção dos indivíduos mais capazes e a criação da nova população através de manipulações genéticas são feitas da forma como apresentada.

Em resumo, o algoritmo simplificado de um algoritmo genético para otimização de problemas não lineares restrito é apresentado a seguir:

#### programa Principal

geração = 0 ;  
 geração da população inicial  $x^i$ ,  $i \in \{1, \dots, NBPV\}$ ;  
 avaliação da função  $f_1(x)$  (execução do PFC);  
 faça enquanto (geração  $\leq$  máximo de gerações)  
   geração = geração + 1;  
   reprodução: (seleção dos sobreviventes)  
   cruzamento: (operação entre pares de indivíduos escolhidos aleatoriamente com uma probabilidade  $pc$ );  
   mutação: (operação aleatória sobre um indivíduo escolhido com uma probabilidade  $pm$ );  
   avaliação da função para cada geração  
 fim do faça enquanto  
 fim do programa principal

## 5. TESTES COMPUTACIONAIS

Foram realizados testes com o sistema de 14 e 30 barras do IEEE, cujas características principais são apresentadas nas tabelas 1 e 2.

Tab. 1 - Sistema 14 barras IEEE.

| NBPV | NL | NT |
|------|----|----|
| 04   | 17 | 3  |

Tab. 2 - Sistema 30 barras IEEE.

| NBPV | NL | NT |
|------|----|----|
| 05   | 37 | 4  |

onde:

NBPV -  $n^o$  de barras de tensão controlada.  
 NL -  $n^o$  de linhas de transmissão.  
 NT -  $n^o$  de transformadores em fase.

Para o sistema de 14 barras as variáveis de controle são as tensões das barras de tensão controlada 2, 3, 6, e 8, totalizando quatro variáveis de otimização

representadas por strings de 16 bits por variável. O valor desejado para as tensões em todas as barras de carga é de 1.00 pu e os limites máximo / mínimo são 1.10 pu e 0.90 pu, respectivamente.

Os limites da geração de reativos nas barras de tensão controlada são dados na tabela 3. Os valores dos parâmetros de penalidade  $\alpha$  e  $\lambda$  utilizados são 10000 e 300, respectivamente.

Tab. 3 - Limites de reativos - Sist. 14 Barras.

| Barra | Qmin    | Qmax   |
|-------|---------|--------|
| 2     | -0.4000 | 0.5000 |
| 3     | 0.0000  | 0.4000 |
| 4     | -0.0600 | 0.2400 |
| 5     | -0.0600 | 0.2400 |

Os seguintes parâmetros genéticos, foram utilizados para este caso: tamanho da população igual a 30; probabilidade de cruzamento igual a 0.8 e probabilidade de mutação igual a 0.010. O ponto ótimo encontrado é representado na tabela 4, em que os desvios dos valores calculados em relação aos desejados foram minimizados.

Ponto ótimo encontrado.

|       |       |       |       |
|-------|-------|-------|-------|
| 1.043 | 1.021 | 0.975 | 1.044 |
|-------|-------|-------|-------|

Tab. 4 - Resultado Numérico - Sist. 14 barras.

| Barra | V     | Q      |
|-------|-------|--------|
| 2     | ---   | 0.2075 |
| 3     | ---   | 0.2071 |
| 4     | 1.019 | ---    |
| 5     | 1.024 | ---    |
| 6     | ---   | 0.1625 |
| 7     | 1.006 | ---    |
| 8     | ---   | 0.2269 |
| 9     | 0.988 | ---    |
| 10    | 0.978 | ---    |
| 11    | 0.973 | ---    |
| 12    | 0.960 | ---    |
| 13    | 0.958 | ---    |
| 14    | 0.955 | ---    |

A evolução do GA para o sistema de 14 barras do IEEE pode ser visualizada na fig. 1, onde é representada uma curva característica do valor da função de minimização para os melhores indivíduos de cada geração.




Fig. 1 - Sist. 14 barras, curva característica valor da função x geração.

Para o sistema de 30 barras as variáveis de controle são as tensões das barras de tensão controlada 2, 5, 8, 11 e 13, totalizando cinco variáveis de otimização representadas por strings de 16 bits por variável. O valor desejado para as tensões em todas as barras de carga é de 1.00 pu e os limites máximo / mínimo são 1.10 pu e 0.90 pu, respectivamente.

Os limites da geração de reativos nas barras de tensão controlada são dados na tabela 5. Os valores dos parâmetros de penalidade  $\alpha$  e  $\lambda$  utilizados são 10000 e 300, respectivamente.

Tab. 5 - Limites de reativos - Sist. 30 Barras.

| Barra | Qmin    | Qmax   |
|-------|---------|--------|
| 2     | -1.0000 | 1.0000 |
| 5     | -1.0000 | 1.0000 |
| 8     | 0.0000  | 3.0000 |
| 11    | 0.0000  | 3.0000 |
| 13    | -1.0000 | 3.0000 |

Os seguintes parâmetros genéticos, foram utilizados para este caso: tamanho da população igual a 30; probabilidade de cruzamento igual a 0.8 e probabilidade de mutação igual a 0.010. O ponto ótimo encontrado é representado na tabela 6, em que os desvios dos valores calculados em relação aos desejados foram minimizados.

Ponto ótimo encontrado.

|       |       |       |       |       |
|-------|-------|-------|-------|-------|
| 0.911 | 0.991 | 1.062 | 1.050 | 1.098 |
|-------|-------|-------|-------|-------|

A evolução do GA para o sistema de 30 barras pode ser visualizada na Fig. 2, onde é representada uma curva característica do valor da função de minimização para os melhores indivíduos de cada geração.

Tab. 6 - Resultado Numérico - Sist. 30 barras.

| Barra | V     | Q      |
|-------|-------|--------|
| 2     | ---   | 0.2739 |
| 3     | 1.001 | ---    |
| 4     | 1.001 | ---    |
| 5     | ---   | 0.5704 |
| 6     | 1.016 | ---    |
| 7     | 0.998 | ---    |
| 8     | ---   | 1.3674 |
| 9     | 1.014 | ---    |
| 10    | 1.007 | ---    |
| 11    | ---   | 0.1845 |
| 12    | 1.021 | ---    |
| 13    | ---   | 0.6052 |
| 14    | 1.006 | ---    |
| 15    | 1.002 | ---    |
| 16    | 1.008 | ---    |
| 17    | 1.001 | ---    |
| 18    | 0.991 | ---    |
| 19    | 0.988 | ---    |
| 20    | 0.992 | ---    |
| 21    | 0.995 | ---    |
| 22    | 0.996 | ---    |
| 23    | 0.993 | ---    |
| 24    | 0.990 | ---    |
| 25    | 1.001 | ---    |
| 26    | 0.983 | ---    |
| 27    | 1.016 | ---    |
| 28    | 1.021 | ---    |
| 29    | 0.996 | ---    |
| 30    | 0.985 | ---    |

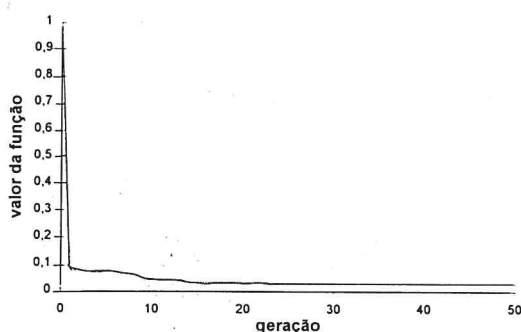


Fig. 2 - Sist. 30 barras, curva característica valor da função x geração.

## 6. CONCLUSÃO

O estudo mostrado neste artigo, visa demonstrar a aplicação do Algoritmo Genético acoplado ao Programa de Fluxo de Carga para otimização de Sistemas Elétricos de Potência, onde a função objetivo é a minimização do desvio de tensão em relação ao valor nominal. A forma como foram

representadas as funções de penalidades utilizadas (limites de tensão nas barras de carga e limites de reativos nas barras de tensão controlada), tem mostrado resultados encorajadores em comparação aos trabalhos encontrados publicados em outros artigos [9]. Os resultados numéricos mostraram a eficiência desta nova abordagem, das funções de penalidades, na resolução do problema de Fluxo de Potência Ótimo.

## 7. REFERÊNCIAS BIBLIOGRÁFICAS

- [1] H. W. Dommel, W. F. Tinney, "Optimal power flow solutions", IEEE Trans., 1968, PAS-87, 1866-1876.
- [2] M.T.Vasconcellos, A. Santos Jr., "Caráter Multiobjetivo do fluxo de Potência Ótimo", XI Congresso Brasileiro de Automática - Anais vol 1, São Paulo, 02-06 Set (1996).
- [3] M.T.Vasconcellos, A. Santos Jr., V. F. da Costa, "Minimização das Perdas de Transmissão como Critério de Melhoria da Estabilidade de Tensão", XI Congresso Brasileiro de Automática - Anais vol 1, São Paulo, 02-06 Set (1996).
- [4] Monticelli, Alcir José - "Fluxo de Carga em Redes de Energia Elétrica", Ed. Edgard Blücher Ltda, São Paulo, 1983.
- [5] Vincens, Ricardo Alberto Loss - "Fluxo de Potência Otimizado, Usando o Modelo Desacoplado, Programação Não-Linear e Técnicas de Esparsidade", Dissertação de Mestrado, UFMG, Belo Horizonte, 1979.
- [6] Baracho, Francisco Ricardo Abrantes Couy - "Estabilidade de Tensão em Sistemas Elétricos de Potência", Dissertação de Mestrado, UFMG, Belo Horizonte, 1992.
- [7] K. Iba. "Reactive Power Optimization by Genetic Algorithm". IEEE Transactions on Power Systems, 9(2):685-692, May 1994.
- [8] Y. Lee, X. Bai, and Y. Park. "Optimization Method for Reactive Power Planning Using a Modified Simple Genetic Algorithm". Presented at the 1995 IEEE Power Engineering Society Winter Meeting, paper 95WM133-9PWRS, Jan./Feb. 1995.
- [9] Carlos R. R. Dornellas, Djalma M. Falcão, Antônio L. B. Bomfim, "Otimização do Despacho de Reativos Utilizando Algoritmos Genéticos", XI Congresso Brasileiro de Automática - Anais vol 1, São Paulo, 02-06 Set (1996).
- [10] João A. Vasconcelos, R. R. Saldanha, L. Krahenbühl, A. Nicolas, "Algoritmo genético aplicado à otimização em eletromagnetismo", Artigo enviado ao Congresso Brasileiro de Eletromagnetismo, UFSC, Florianópolis, 1995.